Classification d'images et détection de visages pour l'identification de membres d'un groupe : approche par descripteurs locaux et déploiement web

Odia Tondwa David[1] (24mot045si@esisalama.org), Munganga Mwayuma Priscille[1] (17mmp253@esisalama.org), NGOY KANKOMBA Khan[1] (25mnk019si@esisalama.org)

[1] Master 1 en Data Science, Faculté des Sciences Informatiques, Université Don Bosco de Lubumbashi, RDC

Résumé -

Ce travail présente une chaîne complète allant de la collecte de données au déploiement d'un prototype de reconnaissance des membres du groupe. Le modèle principal évalué (Modèle 1 : HOG + StandardScaler + k-NN) atteint 86,67 % d'exactitude sur l'ensemble de validation (30 échantillons, 3 classes), avec un macro-F1 de 0,865 et des F1 par classe de 0,952 (david), 0,800 (khan) et 0,842 (priscille). Cette performance dépasse de 53,34 points le niveau du hasard (33,33 %) pour trois classes. Pour la détection, le système Haar frontal/profil détecte au moins un visage dans 29 images sur 30 (96,7 %). Ces résultats confirment que le Modèle 1 est adapté à notre contexte de petit jeu de données grâce au prétraitement (CLAHE), aux descripteurs HOG, à l'équilibrage des classes et au seuil de rejet \"Inconnu\" (0,7), tout en laissant une marge d'amélioration sur les poses difficiles.

Mots-clés -

classification d'images, détection de visages, HOG, k-NN, Streamlit, one-shot learning.

1. Introduction

La reconnaissance automatique de visages et l'attribution d'identités à partir d'images relèvent de la vision par ordinateur et du machine learning. Dans ce projet, l'objectif est de construire une solution complète, depuis l'acquisition des données jusqu'au déploiement d'une interface utilisable par un utilisateur final.

Le travail répond à trois objectifs : (i) préparer un dataset des membres du groupe, (ii) entraîner et évaluer un modèle de classification ainsi qu'un module détection+classification, (iii) déployer le tout dans une application web. L'évaluation est documentée avec des métriques quantitatives afin d'assurer la vérifiabilité des résultats.

2. Revue de littérature

Les méthodes classiques de détection reposent sur les cascades de Haar/LBP (Viola-Jones) [1]. Pour la représentation du visage, HOG [2] reste une baseline robuste et interprétable dans des contextes à faibles ressources.

L'état de l'art en reconnaissance faciale est aujourd'hui dominé par les CNN et les embeddings discriminants, notamment FaceNet [4] et ArcFace [5], offrant une meilleure séparation inter-classes dans l'espace latent. Pour la détection, des approches modernes comme MTCNN [6], RetinaFace ou YOLO-face surpassent souvent les cascades sur les profils, l'occlusion et l'éclairage variable.

Les approches few-shot/one-shot via réseaux siamois [7] sont particulièrement pertinentes lorsque peu d'images par identité sont disponibles. Elles apprennent une métrique de similarité plutôt qu'une classification stricte, et peuvent réduire le besoin en données massives.

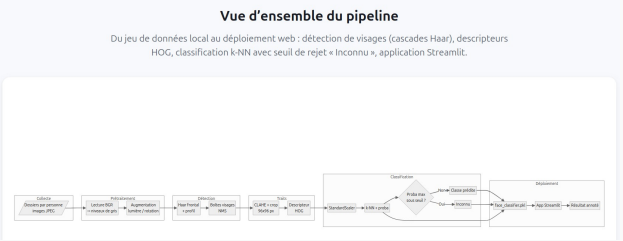

Figure 1. Vue d'ensemble du pipeline : acquisition, détection, extraction de descripteurs, classification, déploiement.

3. Préparation du dataset

Le dataset contient 3 classes (david, khan, priscille), avec 10 images brutes par classe. Les images sont organisées en sous-dossiers par identité. Une augmentation simple (luminosité et rotations légères) est appliquée pour augmenter la variabilité.

Après augmentation, le nombre total d'échantillons utilisés pour la classification est de 150. Cette étape permet de limiter l'impact du faible volume initial et d'améliorer la robustesse aux changements de conditions de prise de vue.

Figure 2. Organisation du jeu de données : un sous-dossier par personne.

4. Implémentation et protocoles expérimentaux

4.1 Modèle de classification (Modèle 1)

Le pipeline de classification est composé de : détection du visage, recadrage 96x96, CLAHE, extraction HOG, standardisation, puis k-NN (k=3, weights=\"distance\"). Le split est stratifié 80/20 avec random_state=42. Le seuil \"Inconnu\" utilisé est 0,7.

4.2 Conditions générales d'évaluation

L'évaluation de la classification est réalisée sur l'ensemble de

validation (30 échantillons : 10 par classe). Métriques rapportées : accuracy, précision, rappel, F1-score et matrice de confusion. La matrice de confusion présentée dans cet article est celle du Modèle 1 uniquement.

metrics.json

Model > artifacts > metrics.json > ...


```
{
  "labels": [
    "david",
    "khan",
    "priscille"
  ],
  "num_samples": 150,
  "train_accuracy": 1.0,
  "val_accuracy": 0.8666666666666667,
  "unknown_threshold": 0.7
}
```


Figure 3. Métriques du Modèle 1 : accuracy train=1,00, validation=0,8667, seuil \"Inconnu\"=0,7.

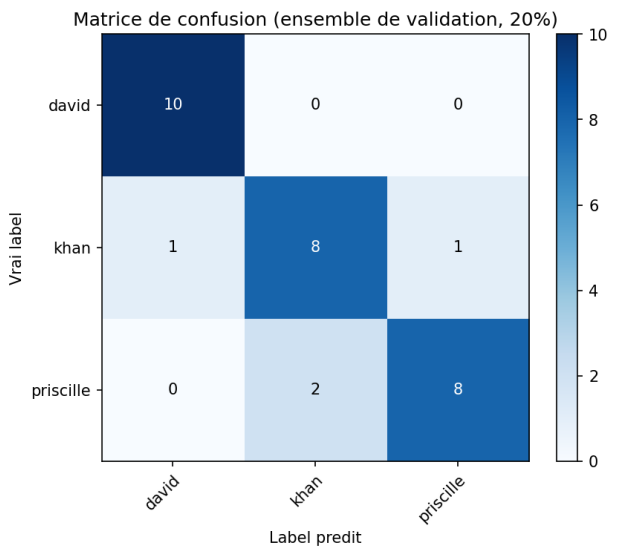

Figure 4. Matrice de confusion du Modèle 1 sur l'ensemble validation (30 échantillons).

4.3 Évaluation de la détection

L'évaluation de la détection est séparée de la classification. Critère retenu : image comptée \"détectée\" si au moins un visage est trouvé. Sur les 30 images brutes du dataset, 29 images sont détectées (96,7 %). Cette mesure est une métrique fonctionnelle ; une évaluation mAP/IoU nécessiterait des annotations de boîtes de référence.

4.4 Déploiement web

L'application Streamlit permet le téléversement et la capture caméra. Chaque visage détecté est annoté avec son identité prédite et un score de confiance. Cela valide l'intégration bout-en-bout des artefacts du modèle dans une interface utilisateur.

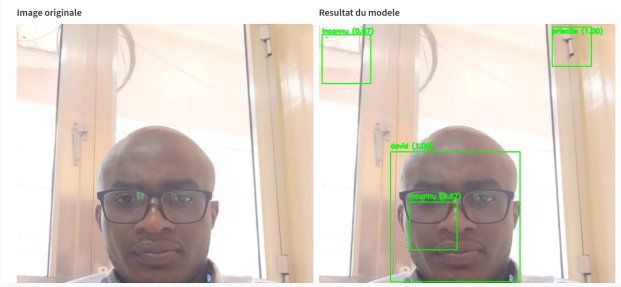

Figure 5. Interface Streamlit en mode upload avec prédiction des visages.

Figure 6. Vue complémentaire de l'application web et du flux de test.

5. Discussion

Les résultats montrent un bon compromis pour un petit dataset. Le Modèle 1 est simple, interprétable et stable, mais sensible aux cas de pose/éclairage extrême. La classe khan reste la plus difficile (F1=0,800), ce qui suggère un besoin d'images plus variées ou d'une représentation plus discriminante.

La détection atteint un taux élevé dans notre cadre contrôlé, mais la généralisation à des scènes plus complexes nécessitera des détecteurs profonds et une évaluation par IoU/mAP. Les approches one-shot/few-shot constituent aussi une piste pertinente avec peu d'images par classe.

6. Conclusion

Ce travail démontre la faisabilité d'un système de reconnaissance faciale déployé en web dans un contexte académique. Le Modèle 1 (HOG + k-NN) dépasse nettement le hasard et fournit des performances utiles pour le cas d'usage cible. Les perspectives prioritaires sont : enrichissement du dataset, ajout d'un second modèle profond pour comparaison quantitative, et évaluation de la détection avec annotations de boîtes.

Références

[1] P. Viola et M. Jones, \"Rapid object detection using a boosted cascade of simple features\", CVPR, 2001.

[2] N. Dalal et B. Triggs, \"Histograms of oriented gradients for human detection\", CVPR, 2005.

[3] Y. LeCun, Y. Bengio et G. Hinton, \"Deep learning\", Nature, 2015.

[4] F. Schroff, D. Kalenichenko et J. Philbin, \"FaceNet: A Unified Embedding for Face Recognition and Clustering\", CVPR, 2015.

[5] J. Deng et al., \"ArcFace: Additive Angular Margin Loss for Deep Face Recognition\", CVPR, 2019.

[6] K. Zhang et al., \"Joint Face Detection and Alignment using Multi-task Cascaded Convolutional Networks\", IEEE SPL, 2016.

[7] G. Koch, R. Zemel et R. Salakhutdinov, \"Siamese Neural Networks for One-shot Image Recognition\", ICML Workshop, 2015.

[8] OpenCV Documentation, Object Detection and HOGDescriptor, https://docs.opencv.org/