Classification d'images et détection de visages pour l'identification de membres d'un groupe : approche par descripteurs locaux et déploiement web

Odia Tondwa David[1] (24mot045si@esisalama.org), Munganga Mwayuma Priscille[1] (17mmp253@esisalama.org), NGOY KANKOMBA Khan[1] (25mnk019si@esisalama.org)

[1] Master 1 en Data Science, Faculté des Sciences Informatiques, Université Don Bosco de Lubumbashi, République Démocratique du Congo

Résumé —

Ce travail présente une chaîne complète allant de la collecte de données à la mise en production d'un prototype de classification de personnes à partir d'images. Nous comparons une démarche de classification « simple » (une personne par cliché) avec une démarche orientée détection multi-visages, où chaque visage est isolé puis classé. L'implémentation repose sur la détection par cascades de Haar, l'extraction de descripteurs HOG (Histogram of Oriented Gradients) et un classifieur de type k-plus proches voisins (k-NN) après normalisation des caractéristiques. Les résultats sont discutés au regard de la taille du jeu de données, du déséquilibre entre classes et des limites des méthodes classiques face aux variations d'éclairage et de pose. Une application web (Streamlit) permet de tester le modèle par téléversement d'image ou capture caméra. Nous concluons sur les pistes d'amélioration, notamment l'apprentissage profond et le transfer learning.

Mots-clés —

classification d'images, détection de visages, HOG, k-NN, déploiement, Streamlit, apprentissage supervisé.

1. Introduction

La reconnaissance automatique de visages et l'attribution d'identités à partir d'images relèvent à la fois de la vision par ordinateur et de l'apprentissage automatique. Dans un contexte pédagogique et appliqué, il s'agit de constituer un jeu de données représentatif, d'entraîner un modèle capable de généraliser, puis d'intégrer ce modèle dans un environnement accessible aux utilisateurs finaux — étape souvent qualifiée de « dernière phase » dans des méthodologies de type CRISP-DM lorsqu'on parle de mise en production.

Ce travail pratique répond à un triple objectif : (i) collecter et prétraiter des images de membres d'un groupe, (ii) entraîner et analyser des modèles pour la classification puis pour la détection et la classification conjointes lorsque plusieurs personnes apparaissent sur une même photographie, (iii) déployer le modèle dans une application web conviviale. Les contraintes imposées (présentation des résultats sous forme d'article, vérifiabilité des performances par rapport au code) incitent à documenter rigoureusement le protocole expérimental et à interpréter les métriques avec prudence lorsque le volume de données reste modeste.

2. Brève revue de la littérature

Les approches historiques de détection de visages s'appuient souvent sur des classifieurs en cascade entraînés sur des features de type Haar ou LBP, popularisés par Viola et Jones [1]. Pour la représentation des visages, les descripteurs HOG [2] capturent la structure locale des contours et des textures ; ils sont encore utilisés comme baseline ou dans des pipelines hybrides avant l'ère dominante du deep learning.

Les réseaux convolutionnels (CNN) et le transfer learning à partir de modèles pré-entraînés (par exemple sur ImageNet ou sur de grands corpus de visages) ont fortement amélioré la robustesse face aux variations de pose, d'illumination et d'occlusion [3]. Les métriques d'évaluation classiques en classification multi-classes incluent la précision, le rappel et leurs moyennes (macro / pondérées), ainsi que la matrice de confusion pour visualiser les confusions entre classes proches.

Enfin, le déploiement de modèles d'apprentissage automatique soulève des questions d'ingénierie : format des artefacts (sérialisation), compatibilité des dépendances, latence d'inférence et interface utilisateur. Les frameworks web légers ou les solutions de type « application de démonstration » facilitent la validation fonctionnelle avant une industrialisation plus lourde (API, conteneurisation, monitoring).

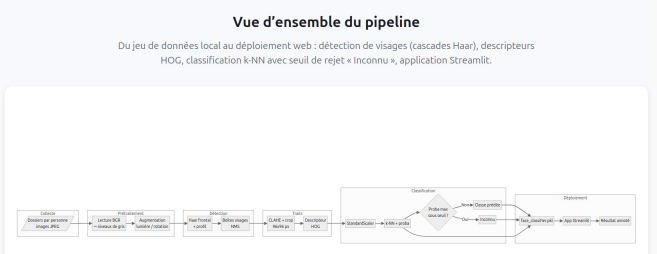

Figure 1. Vue d'ensemble du pipeline : acquisition des images, détection des visages, extraction de descripteurs, classification, déploiement.

3. Préparation du jeu de données

Les images ont été organisées par classe, chaque classe correspondant à un membre du groupe. La diversité des clichés (lunettes, éclairage, distance à la caméra) est un facteur clé de généralisation. Lorsque le nombre d'images par classe est faible, le risque de surapprentissage augmente ; des techniques d'augmentation (variations de luminosité, légères rotations) peuvent artificiellement enrichir la variabilité, sans toutefois remplacer de nouvelles acquisitions réalistes.

Pour la partie « détection + classification », la détection repose sur des cascades (OpenCV) et vise à produire des boîtes englobantes autour des visages avant extraction des descripteurs. La qualité de la détection conditionne directement la qualité des crops utilisés pour l'apprentissage et l'inférence.

Figure 2. Organisation du jeu de données : un sous-dossier par classe (personne) contenant les images d'entraînement.

4. Implémentation

4.1 Approche « standard » : descripteurs HOG et k-NN

Après conversion en niveaux de gris et détection des visages, chaque région faciale est redimensionnée à une taille fixe ; un prétraitement de type CLAHE peut renforcer le contraste localement. Les descripteurs HOG sont ensuite calculés sur une fenêtre 96×96 pixels avec une configuration de cellules et de blocs adaptée (implémentation OpenCV). Les vecteurs obtenus sont normalisés (standardisation) puis classifiés par k-NN avec pondération par distance, approche simple mais interprétable lorsque les classes sont peu nombreuses et le nombre d'échantillons limité.

4.2 Transfer learning et modèles profonds (perspective)

Une voie largement utilisée en pratique consiste à extraire des embeddings à l'aide d'un réseau pré-entraîné (par exemple ResNet, FaceNet-like pipelines, ou modèles spécialisés visages) puis à entraîner uniquement une couche de classification ou un classifieur léger. Cette approche réduit le besoin en données étiquetées massives et améliore souvent la robustesse. Dans le cadre de ce TP, elle est présentée comme perspective d'amélioration et de comparaison méthodologique avec la baseline HOG + k-NN.

Figure 3. Métriques obtenues après entraînement : précision sur les ensembles d'apprentissement et de validation, nombre d'échantillons, seuil de rejet « inconnu ».

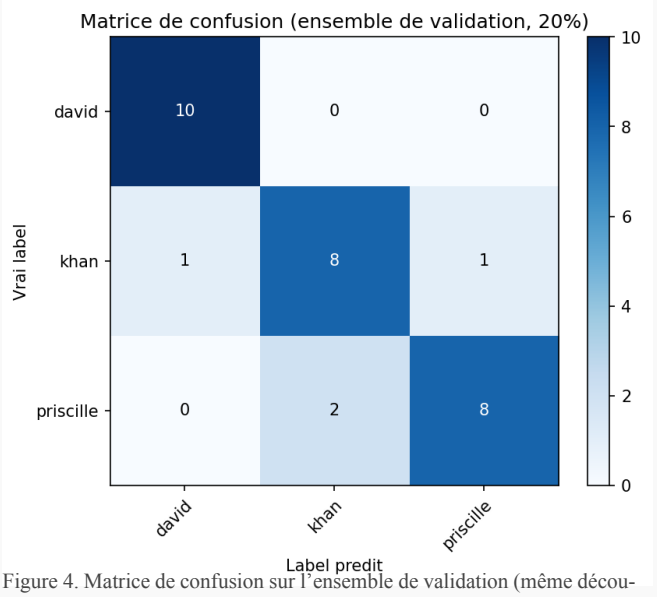

Figure 4. Matrice de confusion sur l'ensemble de validation (même découpage que l'entraînement) : comparaison entre étiquettes réelles et prédictions.

4.3 Déploiement web

L'application développée avec Streamlit permet à l'utilisateur de charger une image ou d'utiliser la caméra. L'image est convertie au format attendu par le pipeline OpenCV ; les visages détectés sont annotés et une étiquette prédite (avec score de confiance) est affichée pour chaque détection. Cette couche « produit » valide l'intégration bout-en-bout du modèle sérialisé.

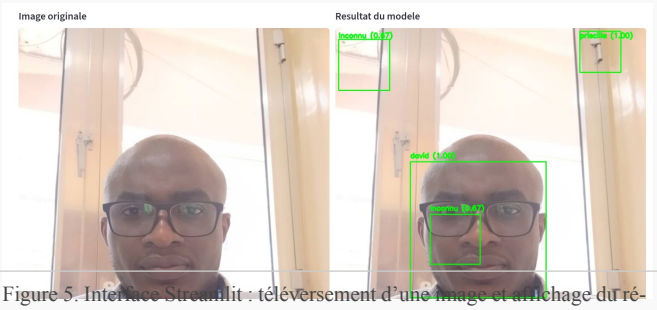

Figure 5. Interface Streamlit : téléversement d'une image et affichage du résultat annoté (visages détectés et classes prédites).

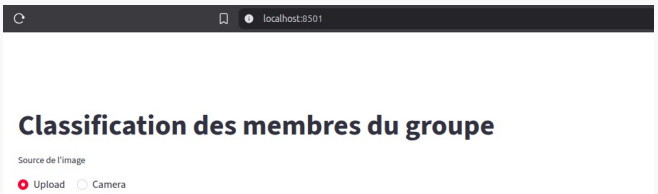

Figure 6. Interface Streamlit : vue complémentaire de l'application (navigation ou autre mode d'interaction selon la capture réalisée).

5. Discussion et pistes d'amélioration

Les performances observées dépendent fortement du nombre d'images par classe et de leur diversité. Un déséquilibre entre classes peut biaiser les prédictions ; des stratégies de rééquilibrage (surdéchantillonnage, pondération) ou la collecte supplémentaire de données sont souvent nécessaires. Les cascades Haar présentent des limites sur les profils marqués ou les faibles contrastes ; des détecteurs plus récents (SSD, RetinaFace,

MTCNN en deep learning) peuvent réduire les cas « aucun visage détecté ».

Le seuil de confiance permet de renvoyer une classe « Inconnu » lorsque la probabilité maximale reste faible, limitant les erreurs grossières mais augmentant potentiellement le taux de rejet. Le réglage de ce seuil doit être validé sur un petit jeu de test indépendant.

En perspective, l'adoption d'embeddings neuronaux et l'affinage partiel (fine-tuning) sur le jeu du groupe, combinés à une annotation plus riche pour la détection (outils type Roboflow pour les boîtes uniquement, entraînement externe), permettraient une comparaison plus équitable avec l'état de l'art.

6. Conclusion

Nous avons présenté une chaîne complète de classification et de détection de visages appliquée à l'identification de membres d'un groupe, avec un déploiement web opérationnel. La baseline HOG + k-NN offre une solution légère et pédagogiquement claire, mais soulève les limites habituelles des petits jeux de données et des détecteurs classiques. Les travaux futurs porteront sur l'intégration de réseaux profonds pré-entraînés, une évaluation quantitative plus systématique et l'extension à une troisième classe conformément au format trinôme du dispositif pédagogique.

Références

[1] P. Viola et M. Jones, « Rapid object detection using a boosted cascade of simple features », *Proceedings of the 2001 IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, 2001.

[2] N. Dalal et B. Triggs, « Histograms of oriented gradients for human detection », *CVPR*, 2005.

[3] Y. LeCun, Y. Bengio et G. Hinton, « Deep learning », *Nature*, vol. 521, pp. 436–444, 2015.

[4] F. Chollet, *Deep Learning with Python*, Manning Publications, éditions récentes.

[5] Documentation OpenCV — Object Detection et HOGDescriptor, *https://docs.opencv.org/*